KHOA HỌC DỮ LIỆU
ĐỒ ÁN CUỐI KỲ

DỰ ĐOÁN TRÊN TẬP DỮ LIỆU LAPTOP

GV: Thầy Trần Trung Kiên

18120379 – Võ Thị Hiếu
18120408 – Trần Ngọc Lan Khanh

Nội dung

- Giới thiệu đồ án
- Thu thập dữ liệu
- Khám phá dữ liệu
- Tiền xử lý dữ liệu
- Xây dựng mô hình
- Đánh giá kết quả
- Tổng kết
- Tham khảo

Giới thiệu đồ án

- Câu hỏi: dự đoán giá của laptop dựa trên các thông số kỹ thuật của laptop?
- Input: Các thông số kỹ thuật của laptop
- Output: Giá laptop dự đoán
- Lợi ích: đem lại thông tin cần thiết cho người muốn mua laptop, với các thông số kỹ thuật cho trước thì giá laptop có thể rơi vào phân khúc giá nào.

Thu thập dữ liệu

- Thu thập dữ liệu trên trang: https://phongvu.vn/

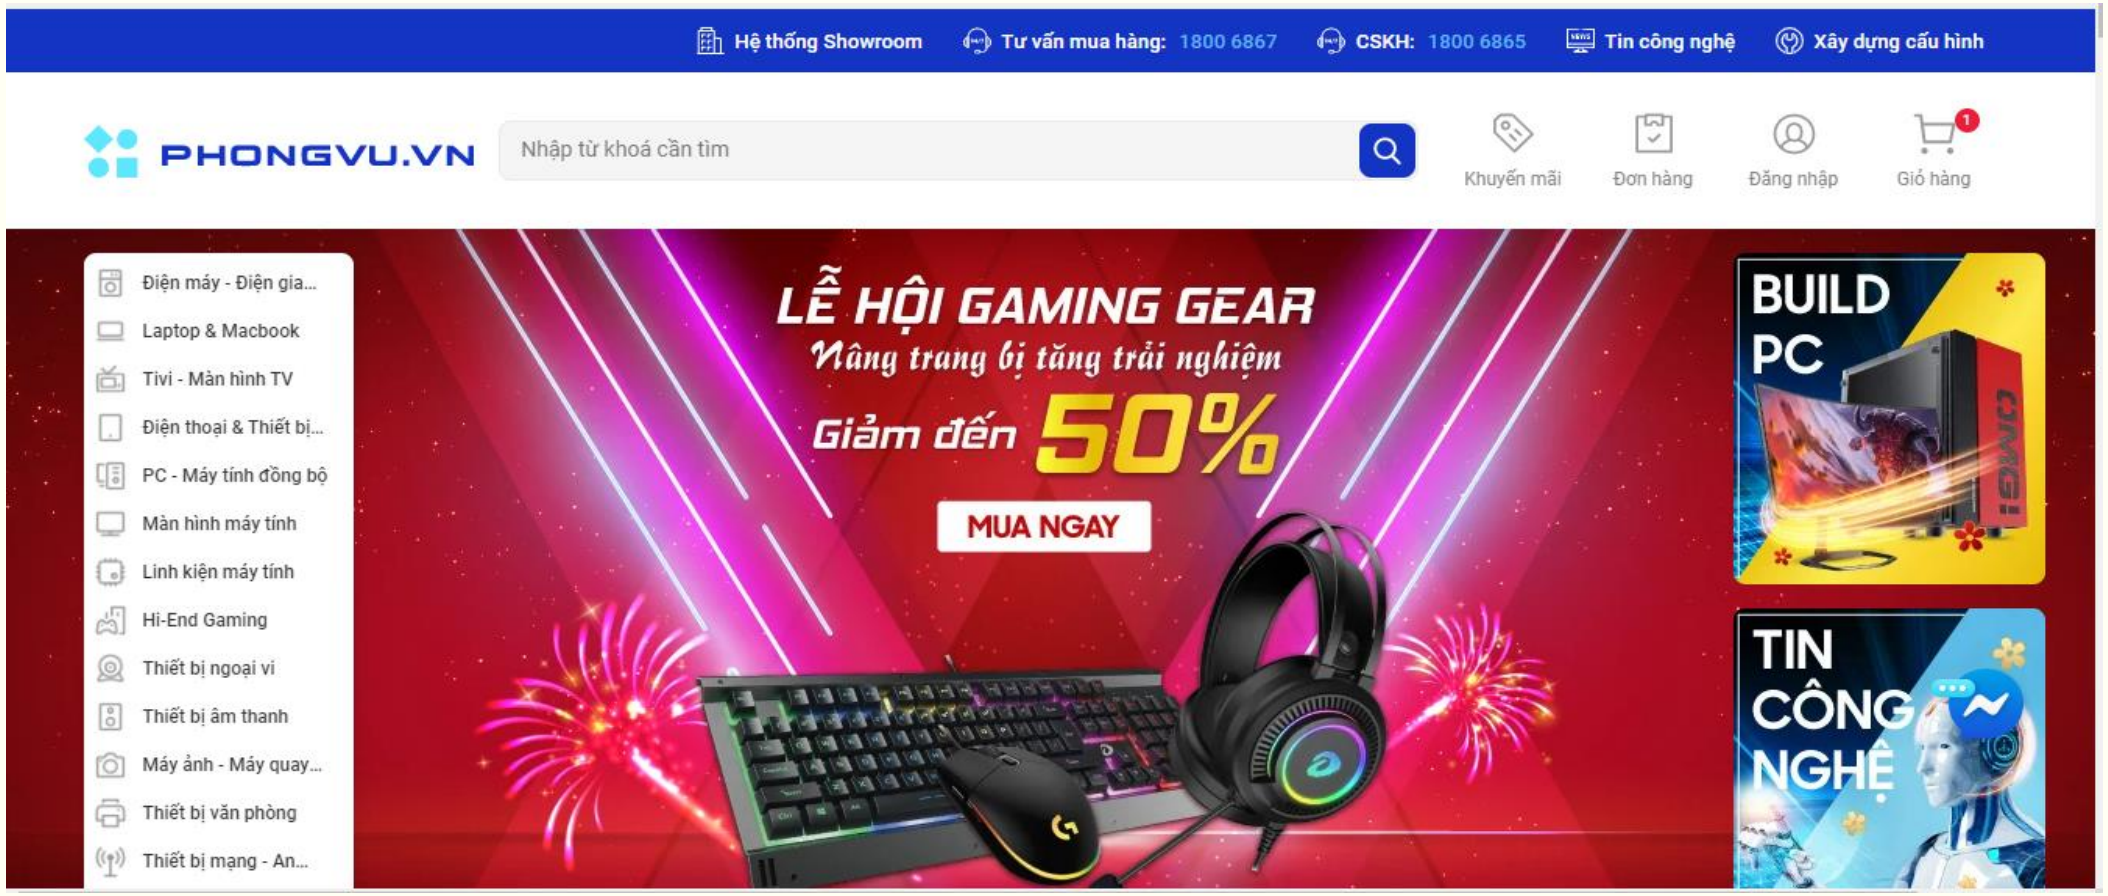

Thu thập dữ liệu

- Dữ liệu bao gồm 782 dòng, có 31 thuộc tín bao gồm:
- URL, Name, Cost, Thương hiệu, Bảo hành, Màu sắc, Series laptop, Part-number, Thế hệ CPU, CPU, Chip đồ họa, RAM, Màn hình, Lưu trữ, Số cổng lưu trữ tối đa, Kiểu khe M.2 hỗ trợ, Cổng xuất hình, Cổng kết nối, Kết nối không dây, Bàn phím, Hệ điều hành, Kích thước, Pin, Khối lượng, Bảo mật, Đèn LED trên máy, Phụ kiện đi kèm, Tính năng, Mic, Ổ đĩa quang, Mô tả bảo hành.
- Chia thành các tập train, tập validate và tập test

Thu thập dữ liệu

- Dữ liệu có các vấn đề như sau:
- Dữ liệu chứa các giá trị thiếu. → loại bỏ các cột có tỷ lệ thiếu hơn 10%
- Một số cột có thể không mang lại ý nghĩa cho việc dự đoán.
- Cột Cost có nhiều giá trị khác nhau → dán nhãn cột Cost, rút gọn số lượng giá trị dự đoán để giảm độ lỗi

Chuyển đổi dữ liệu thô

- Cột Cost có định dạng ‘xx.yy.zz_đồng’, thay dấu ‘.’ thành khoảng trắng và bỏ ‘đồng’ để tách lấy giá trị số nhằm mục đích tính toán.

URL	Name	Cost	ThÆ°Æ¡ng	Bá»£o hÃ nh	MÃ u sá»¯
https://pl	Laptop AS	6.390.000Ä‘	ASUS	24	VÃ ng Ä‘á:
https://pl	Laptop AS	5.990.000Ä‘	ASUS	24	Xanh
https://pl	Laptop AC	6.990.000Ä‘	ACER	12	Äen

Tiền xử lý dữ liệu

Xóa bỏ các thuộc tính:

- ‘Bảo hành’: không có ý nghĩa trong việc dự đoán
- ‘Bảo mật’: Số lượng giá trị thiếu hơn 10%, chỉ có hai gia trị là “Vân tay” và “Khuôn mặt”
- ‘Phụ kiện đi kèm’, ‘Tính năng’, ‘Mic’, ‘Ổ đĩa quang’, ‘Mô tả bảo hành’: giá trị thiếu hơn 10% và không có nhiều ý nghĩa trong việc dự đoán

Tiền xử lý dữ liệu

- Class ColAdderDropper để xóa và gán lại giá trị cho thuộc tính “Name” dựa vào “num_top_titles”.
- Numerical: Điền giá trị thiếu bằng giá trị trung bình của thuộc tính
- Categorical:

❑ Điền giá trị thiếu bằng giá trị phổ biến nhất của thuộc tính

❑ Sử dụng One Hot Encoder

Xây dựng mô hình

- Chọn mô hình MLPRegressor, mô hình này được sklearn hỗ trợ
- Với MLP sau khi chọn được mô hình với num_top_titles tốt nhất sẽ dùng mô hình đó huấn luyện lại full_pipeline trên X_df và y_sr để ra được mô hình cụ thể cuối cùng
- Các thiết lập cho mô hình:

❑ solver: ‘lbfgs’

❑ learning_rate: ‘adaptive’

Đánh giá kết quả

Kết quả model Neural net:

TESTING

In [9]:
```
test_df = pd.read_csv("test.csv")
test_y_sr = test_df["Cost"]
test_X_df = test_df.drop("Cost", axis = 1)
```

In [10]:
```
# test_X_df = pd.read_csv("test.csv")
pred_y = full_pipeline.predict(test_X_df)
test_err = (1 - full_pipeline.score(test_X_df, test_y_sr))*100
test_err
```

Out[10]: 13.826577392354157

Tổng kết

- Thực hành lại quy trình một bài toán Khoa học dữ liệu
- Biết cách sử dụng phương pháp Regression cho bài toán dự đoán.
- Biết được MLPRegressor

Tham khảo

https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPRegressor.html

File BT03-TienXuLy_MoHinhHoa